# Árvores: árvores B e digitais

Prof. Jefferson T. Oliva

Algoritmos e Estrutura de Dados 2 (AE43CP)
Engenharia de Computação
Departamento Acadêmico de Informática (Dainf)
Universidade Tecnológica Federal do Paraná (UTFPR)
Campus Pato Branco

# Sumário

- Árvores B
  - Definições
  - Estrutura de dados
- Operações em Árvore B
- Árvores digitais

# Introdução

- Busca em memória primária
  - Busca sequencial
  - Busca sequencial indexada
  - Busca binária
  - Busca por interpolação
  - Árvore binária de busca
  - Árvore AVL
  - Árvore rubro-negra

# Introdução

- Pesquisa em memória primária vs. secundária
  - Primária: acesso mais rápido, portanto, mais caro

  - Secundária: mais barato, portanto, acesso mais lento

**Árvores B**

# Árvores B

- Amplamente utilizadas para o armazenamento em memória secundária
- Diversas aplicações/ferramentas utilizam árvores B (*B-tree*)
  - Sistemas de arquivos (*e.g.* NTFS e ext4)
  - Banco de dados (*e.g.* Oracle e PostgreSQL)
- Árvores B são estruturas de dados projetadas para a indexação de dados
  - Estrutura mais avançada em relação ao arquivo sequencial indexado

# Árvores B

- Árvore B é n-ária
  - Exemplo de árvore binária de busca

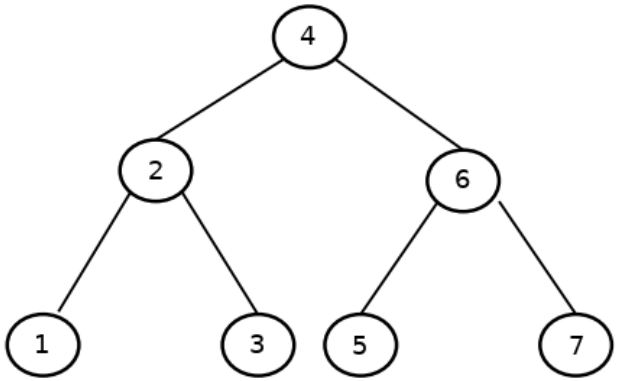


  - Exemplo de árvore B

# Árvores B

- Árvore binária de busca: cada nó tem um elemento e entre 0 e 2 nós filhos
- Árvore n-ária: cada nó pode ter entre 1 e $n - 1$ elementos e até $n$ filhos

- Árvore de busca balanceada
- O nó de uma árvore B também é chamado de **página**
  - Cada nó pode ter mais de um elemento
- Ordem de árvore B: é o número máximo de páginas descendentes que uma página pode ter (Knuth)
  - Em Cormen et al. (2012) é definida como o número mínimo de páginas descendentes que uma página pode ter
  - Nesse material de aula é considerada a definição de Knuth

- Dada uma árvore B de ordem $N$:
  - Página raiz
    - Elementos: entre 1 (mínimo) e $N-1$ (máximo)
    - Descendentes (subárvores): entre 2 e $N$ (caso não seja página folha)
  - Página interna
    - Elementos: entre $\lceil \frac{N}{2} \rceil - 1$ e $N-1$
    - Descendentes (subárvores): entre $\lceil \frac{N}{2} \rceil$ e $N$
  - Página folha
    - Elementos: entre $\lceil \frac{N}{2} \rceil - 1$ e $N-1$
    - Não possui descendentes
    - Todas as páginas folhas estão no mesmo nível (*i.e.* possuem a mesma profundidade)

- Exemplos para uma árvore B de ordem 5 ($N = 5$):

**Página raiz**

- Elementos: entre 1 (mínimo) e $N - 1$ (máximo)
- Descendentes (subárvores): entre 2 e $N$ (caso não seja página folha)

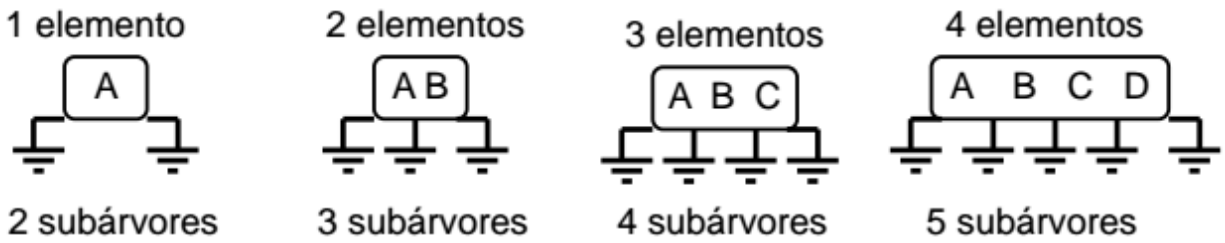


- Quando uma página de árvore B de ordem $N$ tem $N - 1$ elementos, diz-se que a mesma está cheia

- Exemplos para uma árvore B de ordem 5 ($N = 5$):

## Página (nó) interna

- Elementos: entre $\lceil \frac{N}{2} \rceil - 1$ e $N - 1$
- Descendentes (subárvores): entre $\lceil \frac{N}{2} \rceil$ e $N$

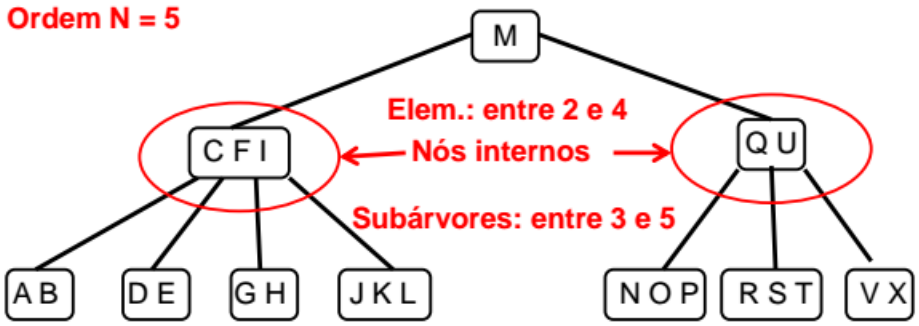

- Exemplos para uma árvore B de ordem 5 ($N = 5$):

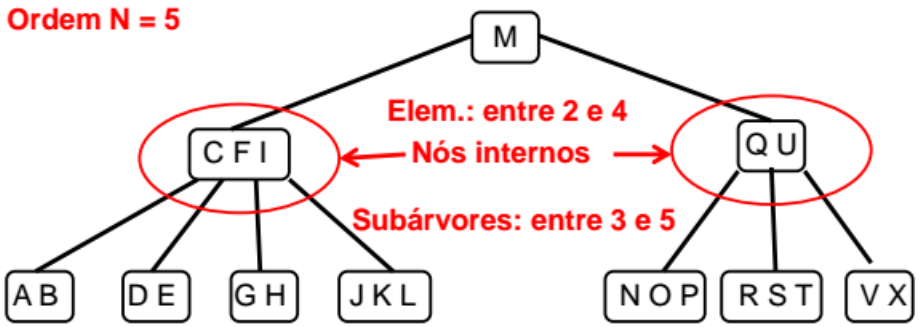


- Dada uma árvore B de ordem 5
  - Cada página interna ou folha pode ter entre 2 (mínimo) e 4 (máximo) elementos
  - Cada página interna pode ter entre 3 (mínimo) e 5 (máximo) descendentes

- Qual é a ordem da árvore B abaixo:

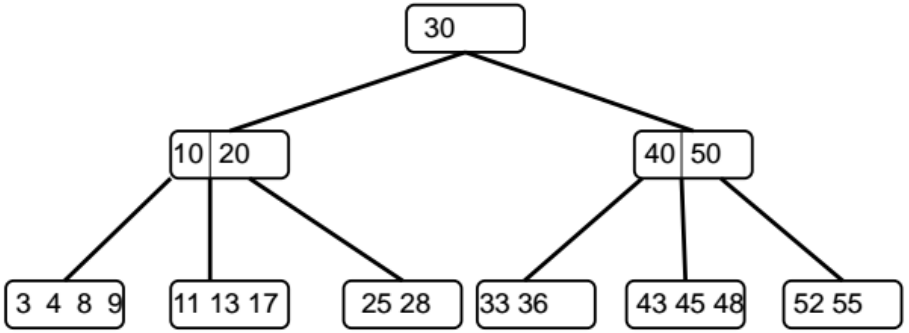

- Qual é a ordem da árvore B abaixo:
  - R.: $N = 5$

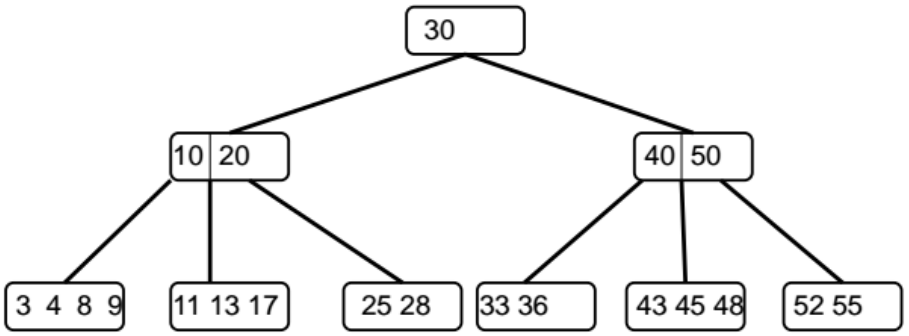

```
#define N ?

typedef struct NodeB NodeB;

struct NodeB{
   int nro_chaves;
   int chaves[N - 1];
   NodeB *filhos[N];
   int eh_no_folha;
};
```

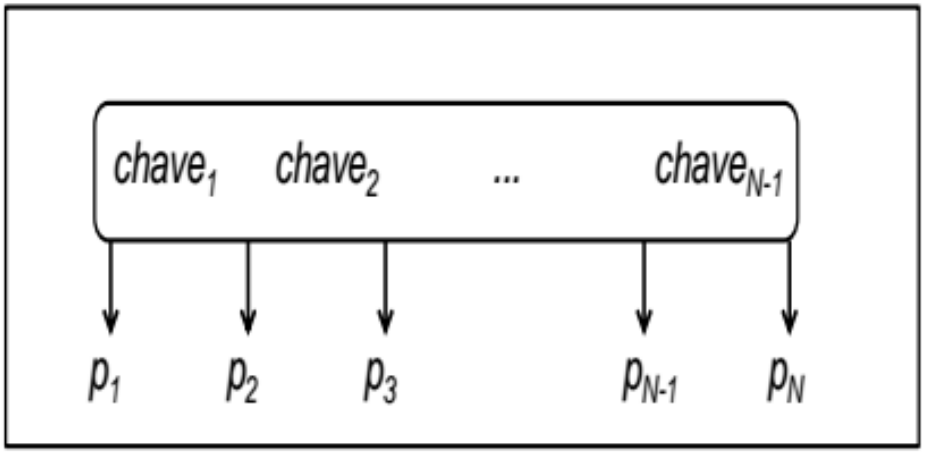
chave1
chave2
...
chaveN-1
p1
p2
p3
pN-1
pN

- Função para inicialização de um ponteiro do tipo NodeB (1)

```
NodeB* criar(){
   NodeB *tree = (NodeB *) malloc(sizeof(NodeB));
   int i;

   tree->eh_no_folha = 1;
   tree->nro_chaves = 0;

   for (i = 0; i < N; i++)
     tree->filhos[i] = NULL;

   return tree;
}
```

- Função para inicialização de um ponteiro do tipo NodeB (2)

```
NodeB* criar(){
   NodeB *tree = (NodeB *) calloc(sizeof(NodeB), 1);
   int i;

   tree->eh_no_folha = 1;

   return tree;
}
```

**Operações em Árvores B**

# Operações em Árvores B

- Pesquisa
- Inserção
- Remoção

# Operações em Árvores B

## Pesquisa

- Semelhante à busca em árvores binárias de busca (incluindo as balanceadas, como as do tipo AVL e rubro-negra)
  - Em vez de termos até duas opções (esquerda e direita) para continuar a busca a partir de um nó, em árvores B podemos ter várias opções
    - Por exemplo, em uma árvore B de ordem N podemos ter até N caminhos para continuar a busca partir de uma página
- Outro exemplo que podemos utilizar para comparar com a árvore B é a busca sequencial indexada
  - A busca começa na página raiz (de forma similar à tabela de índices): caso a chave não seja encontrada, devemos continuar a busca em uma das páginas filhas (se existir)
    - Na busca sequencial indexada, a busca continuaria em um "bloco" do respectivo arquivo
    - Em árvores B, esses "blocos" seriam páginas filhas

- Implementação com busca sequencial

```
int pesquisaSequencial(int key, NodeB *tree){
   int i;
   if (tree != NULL){
     for (i = 0; i < tree->nro_chaves && key < tree->chaves[i];
          i++)
       if (key == tree->chaves[i])
         return 1;
     return pesquisaSequencial(key, tree->filhos[i]);
   }
   return 0;
}
```

- Implementação com busca binária

```
int busca_binaria(int key, NodeB *tree){
   int ini, fim, meio;
   if (tree != NULL){
     ini = 0;
     fim = tree->nro_chaves - 1;
     while (ini <= fim){
       meio = (ini + fim) / 2;
       if (tree->chaves[meio] == key)
         return meio;
       else if (tree->chaves[meio] < key)
         ini = meio + 1;
       else
         fim = meio - 1;
     }
     return ini;
   }
   return -1;
}
```

- Implementação com busca binária

```
int pesquisar(int key, NodeB *tree){
   int pos = busca_binaria(key, tree);
   if (pos >= 0){
     if (tree->chaves[key] == key)
       return 1;
     else
       return pesquisar(key, tree->filhos[pos]);
   }
   return 0;
}
```

- Exemplo: busca sequencial pela chave 20

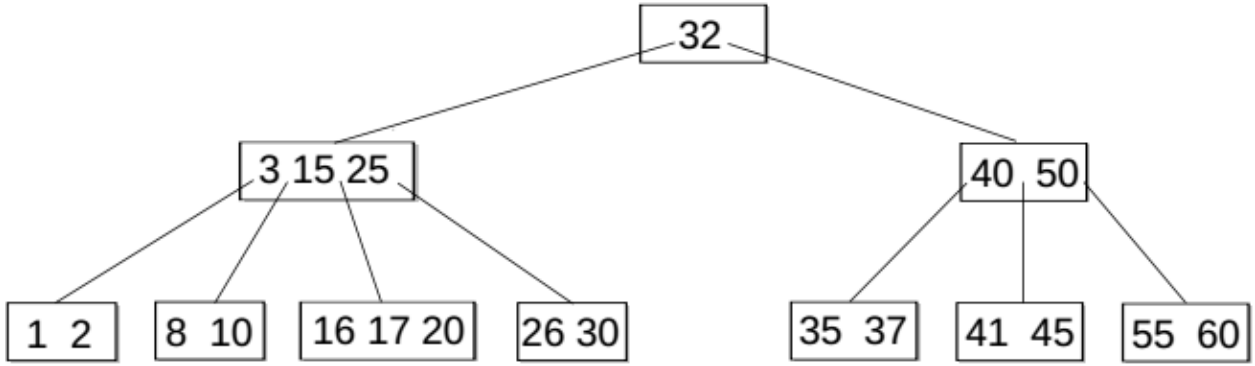

- Exemplo: busca sequencial pela chave 20

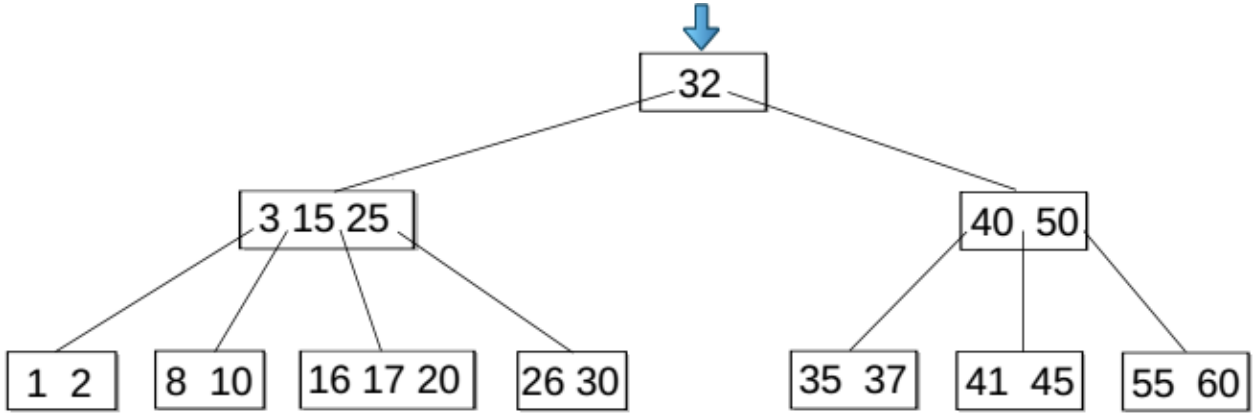

- Exemplo: busca sequencial pela chave 20

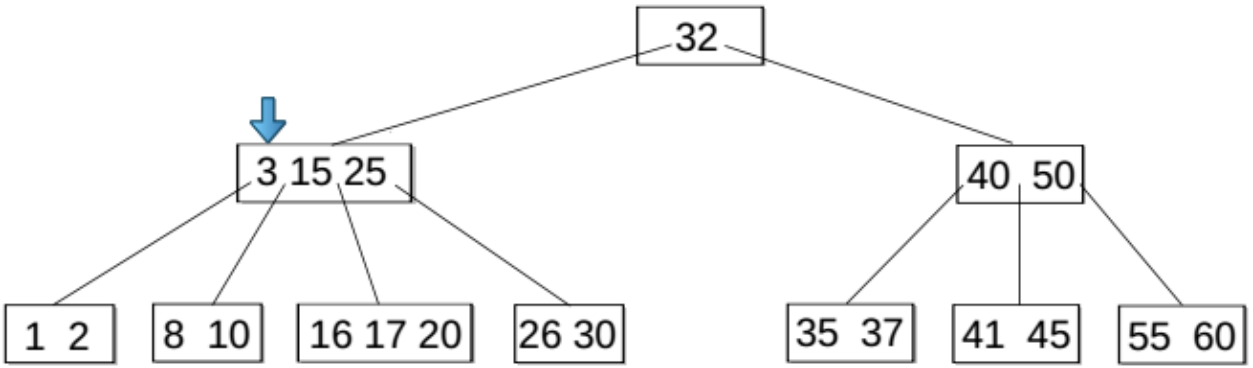

- Exemplo: busca sequencial pela chave 20

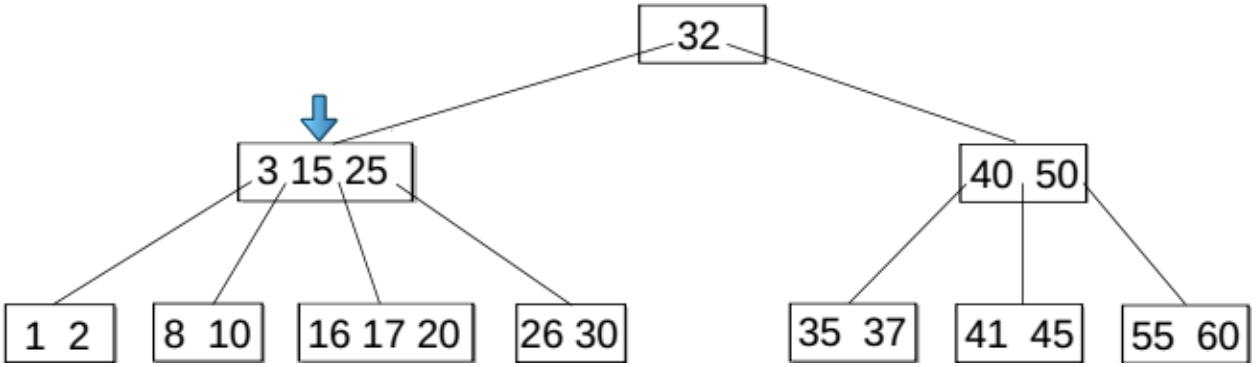

- Exemplo: busca sequencial pela chave 20

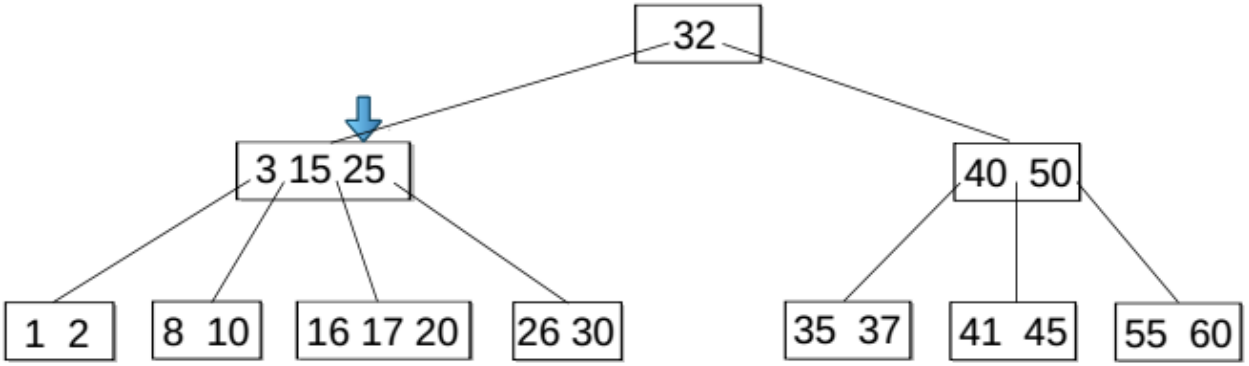

- Exemplo: busca sequencial pela chave 20

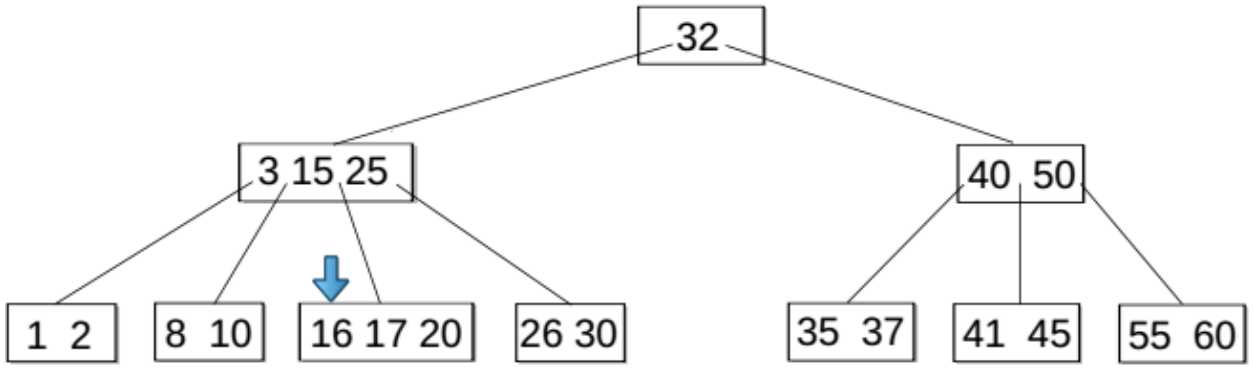

- Exemplo: busca sequencial pela chave 20

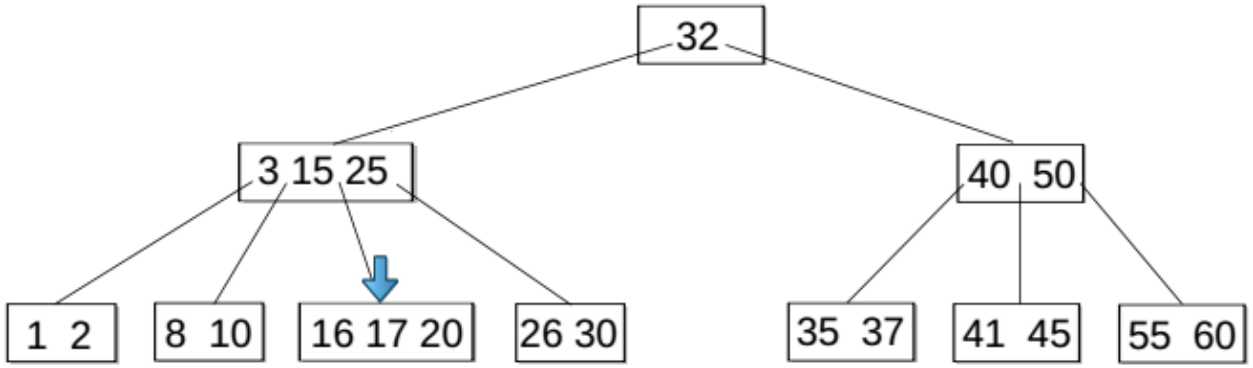

- Exemplo: busca sequencial pela chave 20

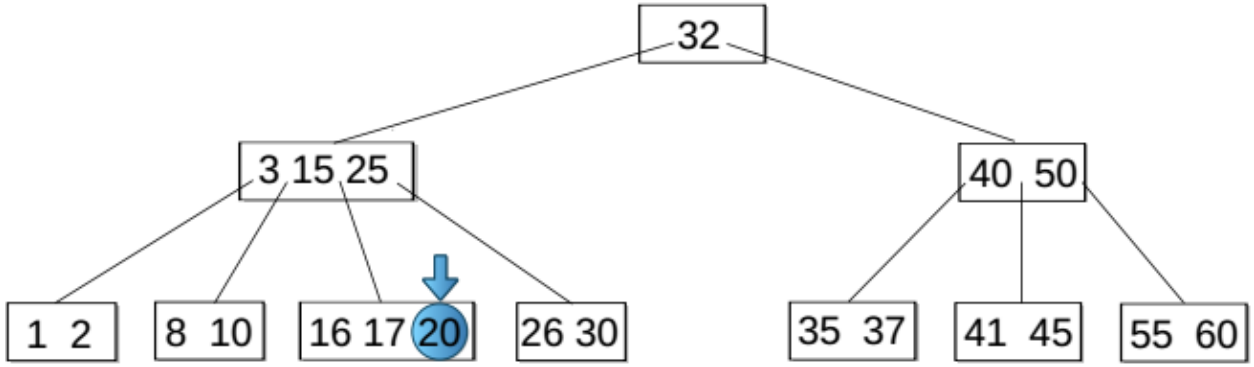

- Complexidade, onde N é a ordem da árvore e M é a quantidade total de chaves
  - Pesquisa sequencial
    - Tempo (pior caso): $O(N \log_N M)$
  - Pesquisa binária
    - Tempo (pior caso): $O(\log_2 M)$, pois $\log_2 N * \log_N M = \log_2 M$

# Operações em Árvores B

## Inserção

- Primeiramente é procurada uma página folha para a inserção de um elemento
  - Diferentemente de árvores binárias de busca, conforme visto em aulas anteriores, nem sempre é necessária a criação de uma nova página folha
  - Se a página não estiver cheia (ou seja, tem menos de $N - 1$ elementos), o novo elemento é alocado nessa pagina
  - Se a página estiver cheia, deverá ser criada uma nova página

- Criação de nova página:
  1. Na página cheia, onde deveria ser inserido o novo elemento, é escolhido um valor intermediário, incluindo a nova chave (elmento)
  2. Em seguida, deve ser criado uma nova página, onde todos os elementos maiores que o valor intermediário deverão ser alocados
  3. A página que está cheia deverá contar com apenas os elementos menores que o valor intermediário, ou seja, a página passará ter a metade dos elementos em relação quando a mesma estava cheia
  4. O valor intermediário deve ser inserido na página pai, que passará a ter uma página filha a mais
     - Caso a página pai esteja cheia, as etapas de 1 a 3 são repetidas

- Criação de nova página:
  - Caso a página pai for raiz e esteja cheia após sucessivas inserções, é criada uma nova página que passará ser raiz
    - Nesse caso, a árvore cresce em altura
  - Após a inserção, a árvore é mantida balanceada

- Exemplo: inserção dos seguintes valores em uma árvore B de ordem 5: 10, 20, 30, 40, 50

- Exemplo: inserção dos seguintes valores em uma árvore B de ordem 5: **10**, 20, 30, 40, 50

- Exemplo: inserção dos seguintes valores em uma árvore B de ordem 5: **20**, 30, 40, 50

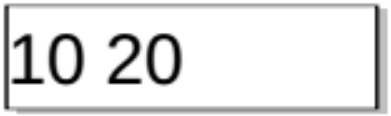

- Exemplo: inserção dos seguintes valores em uma árvore B de ordem 5: **30**, 40, 50

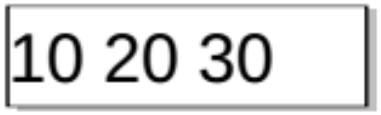

- Exemplo: inserção dos seguintes valores em uma árvore B de ordem 5: **40**, 50

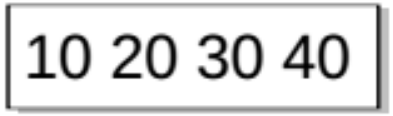

- Exemplo: inserção dos seguintes valores em uma árvore B de ordem 5: **50**

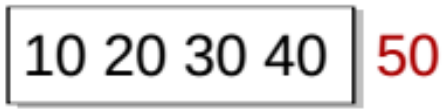

- Exemplo: inserção dos seguintes valores em uma árvore B de ordem 5: **50**

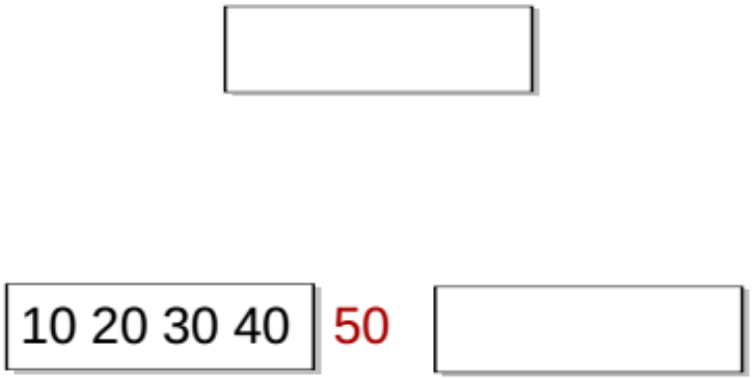

- Exemplo: inserção dos seguintes valores em uma árvore B de ordem 5: **50**

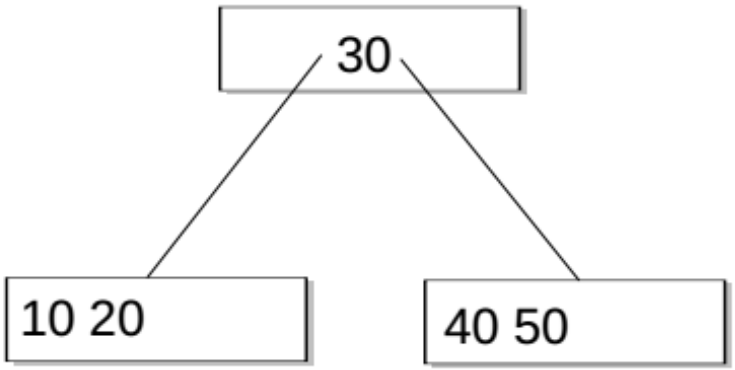

- Outro exemplo: inserção da chave 31 na seguinte árvore B de ordem 5:

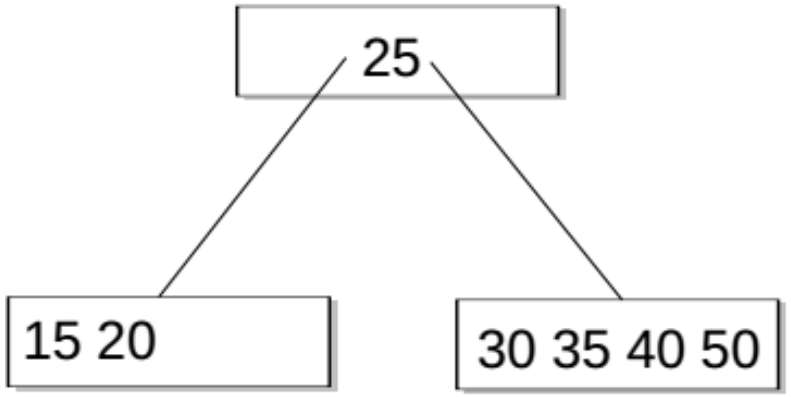

- Outro exemplo: inserção da chave 31 na seguinte árvore B de ordem 5:

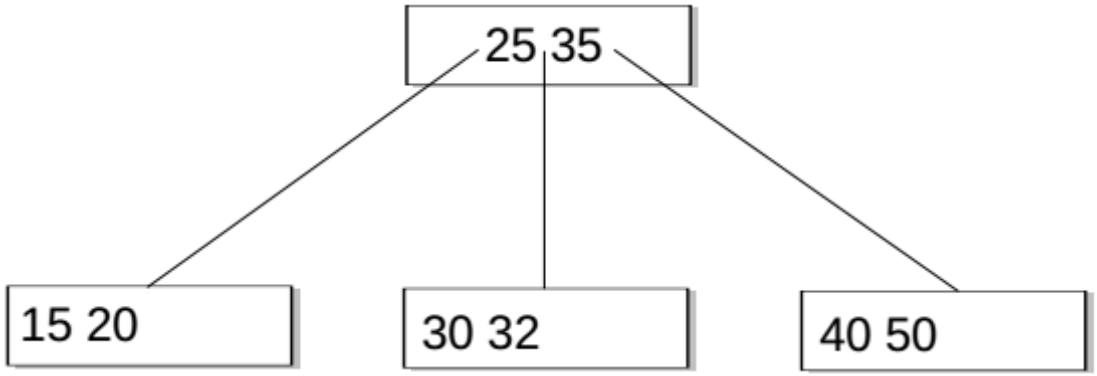

- Complexidade de tempo: $O(log_2 M)$
  - Caso a inserção for implementada com a busca binária
- Espaço extra: $O(log_N M)$

- A remoção ocorre após a busca por uma determinada chave
- Após a remoção, as propriedades de árvore B devem ser mantidas
- Para essa operação, devem ser considerados os seguintes casos
  - Remoção em página folha: caso a página tiver quantidade de elementos a partir de $N/2$, basta reorganizar a página
  - Remoção em página não folha: a chave é trocada com uma sucessora na página folha e, em seguida, eliminar a chave na folha conforme o caso anterior
  - Caso a remoção causar desequilíbrio na página, deve ser procurada uma página irmã que contenha quantidade de chaves maior que o mínimo para redistribuição das chaves

- Para essa operação, devem ser considerados os seguintes casos
  - Caso a remoção causar desequilíbrio na pagina e não houver página irmã que viabilize a redistribuição de chaves, a solução é concatenar duas páginas e atualizar a(s) página(s) pai(s)
    - Caso a página pai ficar desbalanceada, repetir o processo de redistribuição ou concatenação de páginas

- Complexidade de tempo da operação de remoção (caso seja aplicada a operação de busca binária): $O(log_2 n)$

# Árvores B

- Variações da árvore B:
  - B+
  - B*

**Árvores Digitais**

# Árvores Digitais

- Problema da busca: dada uma chave $x$ que deve ser procurada em um conjunto $S$
  - Até o momento foi assumido:
    - Que as chaves são indivisíveis
    - Todas as chaves possuem o mesmo tamanho
  - E se as chaves serem compostas por palavras ou frases?
    - Busca digital: árvores digitais

# Árvores Digitais

- A pesquisa digital é feita da mesma forma em que ocorre em dicionários que possuem os chamados "índices de dedos"
  - A partir da primeira letra, são determinadas todas as páginas quem contêm palavras iniciadas por tal caractere
- Busca digital é vantajosa quando as chaves são consideradas grandes e possuem quantidades diferentes de caracteres
- Exemplo de árvore digital
  - Trie

# Árvores Digitais

- Árvore trie
  - "*information re**TRI**Eval*"
  - Aplicada em recuperação de informação
  - Árvore $m$-ária cujos nós são vetores de $m$ elementos (não confundir com árvores B!)
    - Cada elemento é um digito ou caractere
  - Cada nó no nível (profundidade) $i$ representa as chaves que começam com a mesma sequência de dígitos e/ou caracteres
  - A comparação é feita individualmente por dígito/caractere

# Árvores Digitais

- Árvore trie
  - Exemplo de árvore trie para as seguintes chaves: baki, baku, boruto, nar, naruto, nagato, neji, nejira
  - Nós brancos apontam para NULL e nós cinzas apontam para chaves

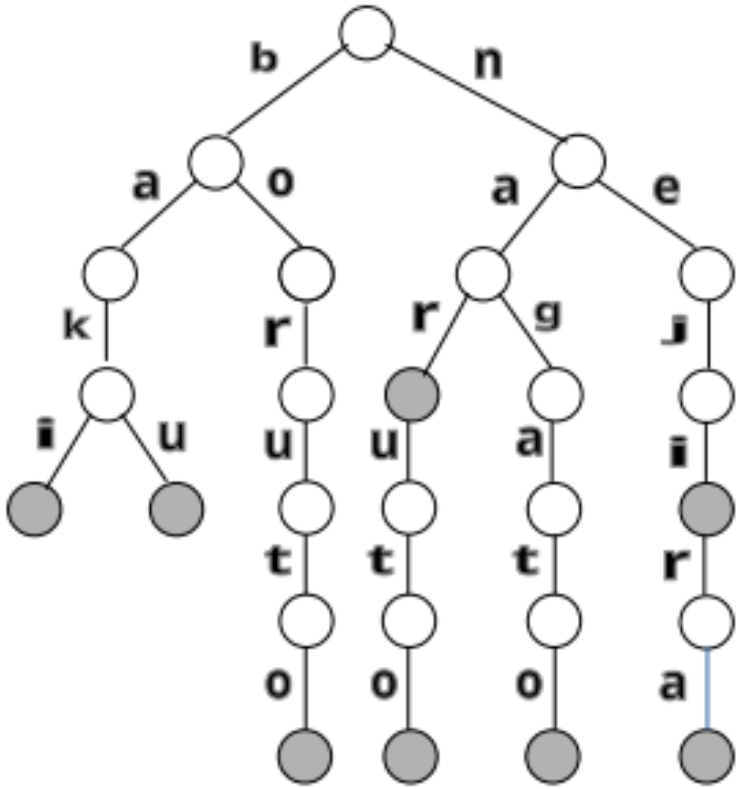

# Árvores Digitais

- Árvore trie
  - Exemplo de busca pela chave "nagato"

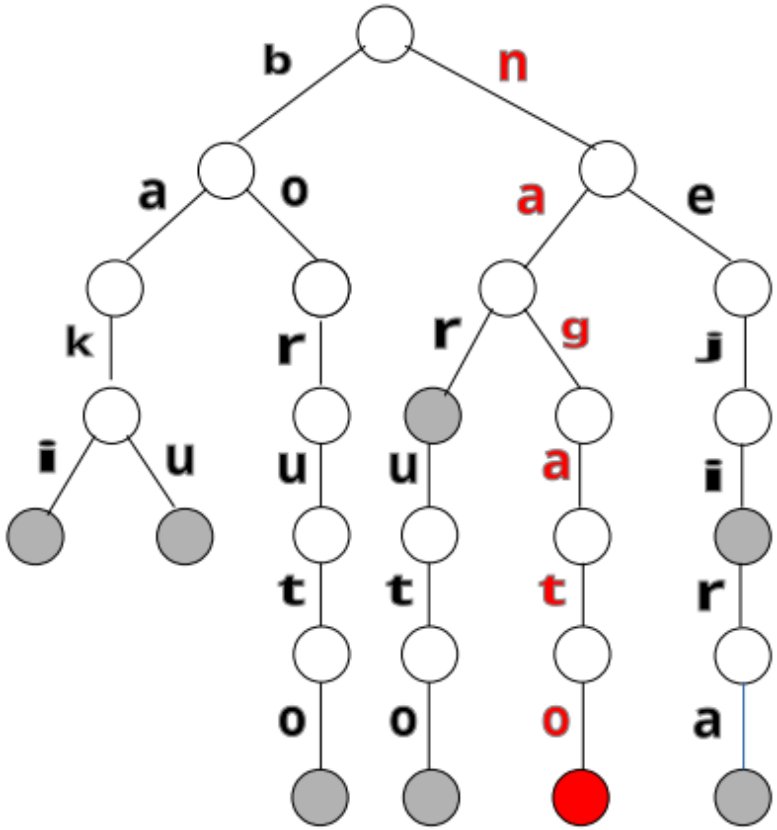

# Árvores Digitais

- Árvore trie
  - Exemplo de busca pela chave "baji"

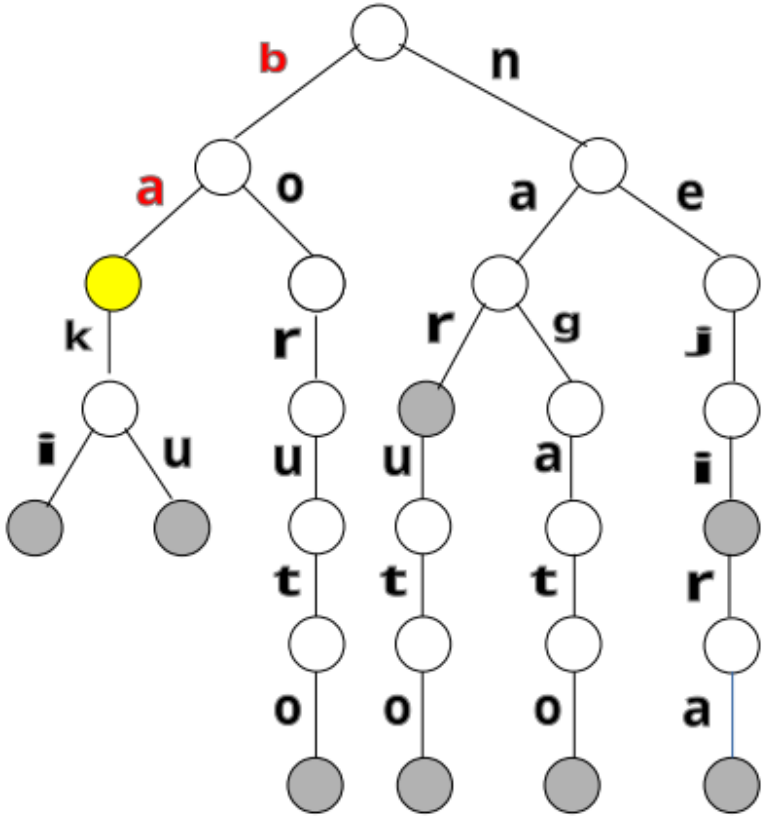

# Árvores Digitais

- Árvore trie
  - Árvore *m*-ária cujos nós são vetores de *m* elementos
    - *m* se refere ao alfabeto, ou seja, a quantidade de caracteres diferentes que árvore tem
    - No exemplo anterior, a árvore possui o seguinte alfabeto: {a, b, e, g, i, j, k, o, r, t, u}
- Quanto maior a quantidade de chaves com prefixos comuns, mais eficiente é a árvore trie
- No entanto, se uma árvore trie possui muitos zigue-zagues no decorrer da sua estrutura, então é considerada ineficiente
- Árvores digitais podem consumir muito espaço de memória!

# Referências I


Cormen, T. H., Leiserson, C. E., Rivest, R. L., Stein, C.
*Introduction to Algorithms*.
Third edition, The MIT Press, 2009.

Marin, L. O.
Árvores B. AE23CP - Algoritmos e Estrutura de Dados II.
Slides. Engenharia de Computação. Dainf/UTFPR/Pato Branco, 2017.

Ziviani, N.
*Projeto de Algoritmos - com implementações em Java e C++*.
Thomson, 2007.