

Análise de Componentes Principais

Prof. Jefferson T. Oliva

Aprendizado de Máquina e Reconhecimento de Padrões (AM28CP)
Engenharia de Computação
Departamento Acadêmico de Informática (Dainf)
Universidade Tecnológica Federal do Paraná (UTFPR)
Campus Pato Branco



- Análise de Componentes Principais
- Espaço PCA
- Exemplo de Aplicação
- PCA vs. LDA

- Maldição da dimensionalidade
- O objetivo dos métodos de redução de dimensionalidade é reduzir a dimensão dos dados originais
 - Redução do tempo de processamento de dados
 - Melhorar a visualização de dados
 - "Facilitar" o aprendizado de máquina
 - etc

Tipos de redução de dimensionalidade


- Supervisionado (e.g. análise discriminante linear)
- Não-supervisionado (e.g. análise de componentes principais)

Análise de Componentes Principais

- PCA (*Principal Component Analysis*)
- Tem o objetivo de projetar os dados em um novo espaço com menos variáveis (componentes), preservando o máximo da variância possível
 - Transforma o conjunto de dados $X = \{x_1, x_2, \dots, x_N\}$ de um espaço dimensional R^M para R^k
 - N é a quantidade de exemplos
 - M é a quantidade de características (dimensão de cada exemplo)
 - x_i é o i -ésimo exemplo
 - Todos os exemplos possuem a mesma dimensão ($x_i \in R^M$)
 - Cada exemplo é representado por M atributos

Análise de Componentes Principais

- A direção do espaço PCA representa a direção da variância máxima dos dados fornecidos
- O espaço de características é composto por um número de componentes principais
 - Cada componente possui uma robustez diferente de acordo com o número de variâncias em sua direção



- O espaço PCA é composto por k componentes principais:
 - Ortonormais: vetores ortonormais possuem comprimento unitário e são ortogonais:

$$v_i^T v_j = \begin{cases} 1, & \text{se } i = j \\ 0, & \text{se } i \neq j \end{cases}$$

- Não correlacionados: v_i e v_j não estão correlacionados se a covariância entre ambos forem iguais a 0, ou seja,
 $\text{Cov}(v_i, v_j) = 0$
- Cada componente representa a direção da variância máxima

Análise de Componentes Principais

- O método PCA é considerado uma transformação ortogonal devido aos seus componentes principais ortogonais por causa da rotação dos eixos originais
- Dois métodos podem ser aplicados para o cálculo dos componentes principais
 - Matriz de covariância
 - Decomposição de valor singular

Análise de Componentes Principais


Matriz de covariância

- Os componentes principais (do espaço PCA) são obtidos em duas etapas
 - ① Cálculo da matriz de covariância (Σ) a partir dos dados de entrada (X)
 - ② Obtenção dos autovetores e dos autovalores a partir da matriz de covariância

Análise de Componentes Principais

Matriz de covariância


- Primeiramente, é calculada a média para cada atributo na matriz de dados (X)
- A matriz de dados é então subtraída com a media, gerando uma matriz de dados centrada na média (D)



Análise de Componentes Principais

Matriz de covariância

- Cálculo da matriz de covariância: $\Sigma = DD^T$



Análise de Componentes Principais

Matriz de covariância


- Matriz de covariância é simétrica ($X = X^T$) e todos os seus autovalores são maiores ou iguais a 0
- A diagonal ($i = j$) da matriz de covariância representa a variância de cada atributo x_i
- Os demais elementos da matriz de covariância representam correlação entre atributos (x_i e x_j) diferentes ($i \neq j$)
- Valor de covariância:
 - Positivo: há uma correlação positiva entre duas variáveis
 - Negativo: há uma correlação negativa entre duas variáveis
 - Zero: não há correlação ou são variáveis independentes

Análise de Componentes Principais

Matriz de covariância

- A matriz de covariância é resolvida calculando os autovalores (λ) e os autovetores (V) da seguinte forma:

$$V\Sigma = \lambda V$$




Análise de Componentes Principais

Matriz de covariância

- Enquanto os autovalores são escalares, os autovetores são vetores diferentes de zero
- Os autovetores representam os componentes principais
 - Cada autovetor representa um componente principal
- Cada autovetor representa uma direção do espaço PCA e os autovalores correspondentes representam o fator de escala, comprimento, magnitude ou a robustez dos autovetores
- O autovetor com o maior autovalor representa o primeiro componente principal e tem a variância máxima
- Os autovalores podem ser iguais quando os componentes principais são iguais

Análise de Componentes Principais

Matriz de covariância



Análise de Componentes Principais

Decomposição de valor singular

- *Singular Value Decomposition (SVD)*
- O principal objetivo do SVD é diagonalizar a matriz de dados ($X \in R^{p+q}$) em três matrizes

$$X = LSR^T = \begin{bmatrix} l_1 & \dots & l_M \end{bmatrix} \begin{bmatrix} s_1 & 0 & 0 & 0 \\ 0 & s_2 & 0 & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & s_N \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} -r_1^T \\ -r_2^T \\ \vdots \\ -r_N^T \end{bmatrix}$$

onde:

- $L_{p \times p}$: vetores singulares esquerdos
- $S_{p \times q}$: matriz diagonal representa os valores singulares que são classificados do maior para o menor ($s_1 \geq s_2 \geq \dots \geq s_N \geq 0$)
- $R_{q \times q}$: vetores singulares direitos

Análise de Componentes Principais

Decomposição de valor singular


- As matrizes L e R são matrizes singulares, ou seja, são de base ortonormais
- Para calcular a matriz SVD, primeiramente devem ser calculadas R^T e S por meio da diagonalização de $X^T X$:

$$X^T X = (LSR^T)^T (LSR^T) = RS^T L^T L S R^T = RS^2 R^T$$

- Sendo que $L^T L = I$
- $L = XRS^{-1}$, onde Xr_i está na direção de s_i ;
- R representa os autovetores de $X^T X$ ou componentes principais no espaço PCA

Análise de Componentes Principais

Decomposição de valor singular



Análise de Componentes Principais

Decomposição de valor singular

- Para obter o espaço PCA, a matriz de covariância ($\Sigma = DD^T$) deve ser calculada
 - O SVD da matriz de covariância é feito da seguinte forma:
$$DD^T = (LSR^T)^T(LSR^T) = RS^T L^T L S R^T = RS^2 R^T = (SVD(D^T))^2$$
Lembrando que $L^T L = I$
 - S^2 representa os autovalores de $D^T D$ ou DD^T
 - R representa os autovetores de DD^T

Análise de Componentes Principais

Decomposição de valor singular

- A raiz quadrada dos autovalores calculados pelo método da matriz de covariância é igual aos valores singulares do método SVD
- Os autovetores de Σ são iguais às colunas de R
- Desse modo, os autovalores e autovetores calculados pelos dois métodos são iguais


Espaço PCA

- Para a redução da dimensionalidade de n atributos para k componentes principais, os k autovetores de maiores valores devem ser selecionados
 - O autovetores restantes são ignorados ou descartados
 - Os k autovetores de maiores valores são usados para preservar a quantidade máxima de variância, ou seja, preservar os dados originais
- Em seguida, com a realização do produto escalar entre o conjunto de dados centrados na média D e o conjunto de k autovetores W , obtém-se um conjunto de componentes com dimensão $m \times k$, onde m é a quantidade de exemplos

$$Y = W^T D = \sum_{i=1}^N W^T(x_i - \mu)$$


Espaço PCA

- Seleção dos k componentes principais



Espaço PCA

- Os dados originais são projetados no espaço PCA com a dimensão reduzida de M para k



- Os dados originais podem ser reconstruídos novamente

$$\hat{X} = WY + \mu = \sum_{i=1}^N Wy_i + \mu$$

- Onde \hat{X} representa os dados reconstruídos
- O desvio entre os dados originais e os dados reconstruídos é chamado de erro de reconstrução ou resíduos

$$Erro = X - \hat{X} = \sum_{i=1}^N (x_i - \hat{x}_i)^2 \quad (1)$$

- Selecionar um grande número de componentes principais aumenta a variância total de W e diminui o erro entre os dados reconstruídos e os originais
 - A robustez da PCA é determinada pelo número de autovetores selecionados (k) e é medida pela soma dos autovalores selecionados, que é chamado de variância total
- A robustez do espaço de dimensão inferior é medida pela razão entre a variância total de W para a variância total

$$Robustez = \frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^M \lambda_i}$$

Algorithm 1 : Calculating PCs using Covariance Matrix Method.

- 1: Given a data matrix ($X = [x_1, x_2, \dots, x_N]$), where N represents the total number of samples and x_i represents the i^{th} sample.
 - 2: Compute the mean of all samples as follows, $\mu = \frac{1}{N} \sum_{i=1}^N x_i$.
 - 3: Subtract the mean from all samples as follows, $D = \{d_1, d_2, \dots, d_N\} = \sum_{i=1}^N x_i - \mu$.
 - 4: Compute the covariance matrix as follows, $\Sigma = \frac{1}{N-1} D \times D^T$.
 - 5: Compute the eigenvectors V and eigenvalues λ of the covariance matrix (Σ).
 - 6: Sort eigenvectors according to their corresponding eigenvalues.
 - 7: Select the eigenvectors that have the largest eigenvalues $W = \{v_1, \dots, v_k\}$. The selected eigenvectors (W) represent the projection space of PCA.
 - 8: All samples are projected on the lower dimensional space of PCA (W) as follows, $Y = W^T D$.
-

Exemplo de Aplicação

Exemplo de Aplicação

- Dada a matriz $X = \{x_1, \dots, x_8\}$ abaixo:

$$X = \begin{bmatrix} 1.00 & 1.00 & 2.00 & 0.00 & 5.00 & 4.00 & 5.00 & 3.00 \\ 3.00 & 2.00 & 3.00 & 3.00 & 4.00 & 5.00 & 5.00 & 4.00 \end{bmatrix}$$

- Médias (μ) de X :

$$\mu = \begin{bmatrix} 2.63 \\ 3.63 \end{bmatrix}$$

- Obtenção de $D = X - \mu$

$$X = \begin{bmatrix} -1.63 & -1.63 & -0.63 & -2.63 & 2.38 & 1.38 & 2.38 & 0.38 \\ -0.63 & -1.63 & -0.63 & -0.63 & 0.38 & 1.38 & 1.38 & 0.38 \end{bmatrix}$$

Exemplo de Aplicação

- Matriz de covariância (Σ), autovalores (λ) e autovetores (V)

$$\Sigma = \begin{bmatrix} 3.70 & 1.70 \\ 1.70 & 1.13 \end{bmatrix} \quad \lambda = \begin{bmatrix} 0.28 & 0.00 \\ 0.00 & 4.54 \end{bmatrix} \quad V = \begin{bmatrix} 0.45 & -0.90 \\ -0.90 & -0.45 \end{bmatrix}$$

- O segundo autovalor (λ_2) é maior que o primeiro (λ_1)
- O segundo autovalor corresponde a $\frac{4,54}{0,28+4,28} \approx 94,19\%$ do total dos autovalores, o que reflete a sua robustez em relação ao primeiro autovalor
- Desse modo, o segundo autovetor (segunda coluna de V) aponta para a direção da variância máxima e, portanto, representa o primeiro componente principal do espaço PCA

Exemplo de Aplicação


- Para calcular os dados projetados, primeiro os dados de centralização média foram projetados em cada autovetor ($Y_{v1} = v_1^T D$ e $Y_{v2} = v_2^T D$, ou seja, $V^T D$):

$$Y_{v1} = [-0.16 \quad 0.73 \quad 0.28 \quad -0.61 \quad 0.72 \quad -0.62 \quad -0.18 \quad -0.17]$$

$$Y_{v2} = [1.73 \quad 2.18 \quad 0.84 \quad 2.63 \quad -2.29 \quad -1.84 \quad -2.74 \quad -0.50]$$

PCA vs. LDA


- PCA e LDA (*linear discriminant analysis* – análise discriminante linear) são métodos de transformação de linear comumente utilizados na redução de dimensionalidade
 - PCA é não-supervisionado, pois a classe dos exemplos é "ignorada" e o seu objetivo é encontrar as direções (componentes principais) que maximizem a variância dos dados
 - LDA é supervisionado e tem o objetivo de obter as direções (discriminantes lineares) que maximizem a separação entre classes



- PCA
 - Minimiza o erro de projeção
 - Maximiza a variância dos pontos projetados
 - Exemplo: redução do número de características de uma face (reconhecimento facial)
- LDA
 - Maximiza a distância entre as classes
 - Minimiza a distância dentro das classes
 - Exemplo: separação de rostos em grupos masculinos e femininos (reconhecimento facial)


- Caso todos os autovalores tenham magnitude semelhante, então os dados utilizados já estão projetados em um "bom" espaço de características
- Se alguns dos autovalores forem muito maiores em comparação com os outros, o interesse é a manutenção de autovetores com maiores autovalores, pois contêm mais informações sobre a distribuição dos dados de entrada

- Na redução de dimensionalidade, a qualidade da aproximação depende da quantidade do número de componentes principais utilizados e pode ser mensurada por meio da avaliação proporção de variância total explicada por esses componentes
- Cenário em que o PCA tem desempenho beneficiado: a direção da variância máxima é horizontal e as classes são separadas horizontalmente




Considerações Finais

- Cenário em que o PCA tem desempenho prejudicado: a direção da variância máxima é horizontal, mas as classes são separadas verticalmente



- Como o PCA é linear, o seu desempenho degrada caso o interesse seja a visualização de dependências não lineares



-  BISHOP, C. M.
Pattern Recognition and Machine Learning.
Springer, 2006.
-  CASANOVA, D.
PCA x LDA. Aprendizado de Máquina.
Slides. Engenharia de Computação. Dainf/UTFPR, 2020.
-  SMITH, L. I.
A tutorial on principal components analysis. 2002.
-  THARWAT, A.
Principal Component Analysis (PCA) : An Overview
ResearchGate, 2016.



THARWAT, A.

Principal component analysis - a tutorial

International Journal of Applied Pattern Recognition,
3(3) (2016) 197-240.