

# Extração Automática de Características

Prof. Jefferson T. Oliva  
jeffersonoliva@utfpr.edu.br

Processamento de Imagens  
Engenharia de Computação  
Departamento Acadêmico de Informática (Dainf)  
Universidade Tecnológica Federal do Paraná (UTFPR)  
Campus Pato Branco



This work is licensed under a Creative Commons "Attribution-ShareAlike 4.0 International" license.




- Descritores SIFT

## Descritores SIFT

# Descritores SIFT


- SIFT: *Scale Invariant Feature Transform*
- Extração automática de características
- São invariantes à rotação, o que significa que, mesmo que a imagem seja girada, podemos encontrar os mesmos cantos
  - Os cantos também permanecem cantos na imagem rotacionada
- Mas e a escala? Um canto pode não ser um canto se a imagem for dimensionada




- Os descritores SIFT são pontos-chave que são invariantes em escala
  - Extraem pontos-chave e calculam seus descritores
- É utilizada a filtragem por espaço de escala, baseado em “Laplace of Gaussian” (LoG) com vários valores de  $\sigma$
- Assim, podemos encontrar os máximos locais na escala e no espaço, o que nos dá uma lista de valores  $(x, y, \sigma)$ , o que significa que existe um ponto-chave potencial em  $(x, y)$  na escala  $\sigma$
- Mas o LoG é caro computacionalmente e, dessa forma, o algoritmo SIFT usa diferença de Gaussianas (DoG – *difference of Gaussians*), que é uma aproximação de LoG

# Descritores SIFT

- O processo de diferença de Gaussianas é feito para diferentes oitavas da imagem na pirâmide Gaussiana
- A diferença de gaussiana é obtida como a diferença de desfoque gaussiano de uma imagem com dois  $\sigma$  diferentes, sejam  $\sigma$  e  $k\sigma$



- Uma vez que a diferença de Gaussianas é encontrada, as imagens são procuradas por extremos locais sobre escala e espaço
  - Por exemplo, um pixel em uma imagem é comparado com seus 8 vizinhos, bem como 9 pixels na próxima escala e 9 pixels nas escalas anteriores
  - Se for um extremo local, é um ponto-chave potencial



- Em relação a diferentes parâmetros, são indicados
  - Número de oitavas = 4
  - Número de níveis de escala = 5
  - $\sigma$  inicial = 1.6
  - $k = \sqrt{2}$
- Agora o descritor de ponto-chave é criado
  - Uma vizinhança de  $16 \times 16$  ao redor do ponto-chave é tomada
  - Divisão em 16 sub-blocos de tamanho  $4 \times 4$
  - Para cada sub-bloco, um histograma de orientação de 8 bins é criado
  - Assim, um total de 128 valores bin estão disponíveis
  - Representação como um vetor para formar o descritor de ponto-chave
  - Além disso, várias medidas são tomadas para obter robustez contra mudanças de iluminação, rotação etc



- Exemplo abaixo: em comum temos a torre Eiffel





Smaller Image of Eiffel Tower









Rotated Image of Eiffel Tower



- Construindo o filtro Gaussiano




- Construindo o filtro Gaussiano

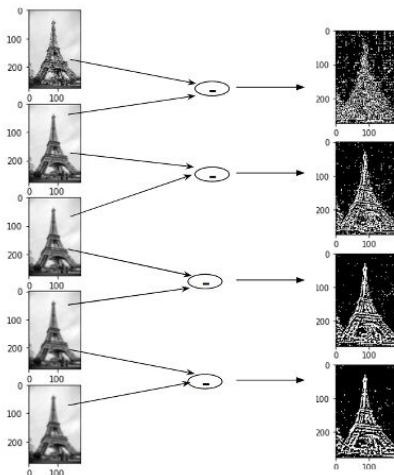


# Descritores SIFT

- Construindo o filtro Gaussiano: 4 oitavas e 5 vezes o filtro
  - As imagens foram divididas pela metade a partir da original
  - Para cada imagem filtrada, novas versões foram criadas




- Diferença Gaussiana: algoritmo de aprimoramento de características que envolve a subtração de uma versão desfocada de uma imagem original de outra versão menos desfocada do original



- Localização dos pontos-chave
  - Depois que as imagens forem criadas, a próxima etapa é encontrar os pontos-chave importantes da imagem que podem ser usados para correspondência de características
  - A ideia é encontrar os máximos e mínimos locais para as imagens em duas etapas:
    - Encontre os máximos e mínimos locais: para isso, percorremos cada pixel da imagem e os comparamos com os pixels vizinhos
    - Remover pontos-chave de baixo contraste (seleção de ponto-chave)
  - Isso significa que cada valor de pixel é comparado com 26 outros valores de pixel para descobrir se é o máximo/mínimo local chamado extremo

- O pixel marcado com x é comparado com os pixels vizinhos (em verde) e é selecionado como ponto-chave ou ponto de interesse se for o maior ou o menor entre os vizinhos



- Alguns pontos-chave podem não ser robustos ao ruído, sendo necessária uma verificação final para garantir que temos os pontos-chave mais precisos para representar as características da imagem
  - Para lidar com os pontos-chave de baixo contraste, uma expansão de Taylor de segunda ordem é calculada para cada ponto-chave
  - Se o valor resultante for menor que 0,03 (em magnitude), rejeitamos o ponto-chave
- Atribuição de orientação: nesta fase, temos um conjunto de pontos-chave estáveis para as imagens
  - Atribuiremos agora uma orientação a cada um desses pontos-chave para que sejam invariantes à rotação
  - Podemos novamente dividir esta etapa em duas etapas menores: cálculo do módulo e da orientação



- Atribuição de orientação:
  - Digamos que queremos encontrar a magnitude e a orientação do valor do pixel em vermelho
    - Para isso, calcularemos os gradientes nas direções x e y tomando a diferença entre 55 e 46 e 56 e 42, resultando em  $G_x = 9$  e  $G_y = 9$ , respectivamente

35	40	41	45	50
40	40	42	46	52
42	46	50	55	55
48	52	56	58	60
56	60	65	70	75

- Atribuição de orientação:
  - Digamos que queremos encontrar a magnitude e a orientação do valor do pixel em vermelho
    - Uma vez que temos os gradientes, podemos encontrar a magnitude ( $M$ ) e a orientação ( $\Phi$ ) usando as seguintes equações:


$$M = \sqrt{G_x^2 + G_y^2} = 16,64$$

$$\Phi = \arctan \frac{G_y}{G_x} = 57,17$$

35	40	41	45	50
40	40	42	46	52
42	46	50	55	55
48	52	56	58	60
56	60	65	70	75

- Descritores:
  - Etapa final do SIFT: temos pontos-chave estáveis que são invariantes à escala e à rotação
  - São usados os pixels vizinhos, suas orientações e sua magnitude para gerar uma 'impressão digital' única para este ponto-chave chamado de 'descriptor'
  - Além disso, como usamos os pixels circundantes, os descritores serão parcialmente invariantes à iluminação ou brilho das imagens
  - Primeiro, é utilizada uma vizinhança de  $16 \times 16$  ao redor do ponto-chave
    - Este bloco de  $16 \times 16$  é dividido em sub-blocos de  $4 \times 4$  e para cada um desses sub-blocos, geramos o histograma usando magnitude e orientação

- Descritores



- Exemplo OpenCV

```
import cv2
import matplotlib.pyplot as plt
```

```
img1 = cv2.imread('eiffel_2.jpeg')
gray1 = cv2.cvtColor(img1, cv2.COLOR_BGR2GRAY)
```

```
sift = cv2.xfeatures2d.SIFT_create()
keypoints_1, descriptors_1 =
sift.detectAndCompute(img1, None)
img_1 = cv2.drawKeypoints(gray1, keypoints_1, img1)
plt.imshow(img_1)
```

- SIFT é um algoritmo lento
- A alternativa é usar o algoritmo SURF, contudo, ele possui menor acurácia
- Melhor resultado em imagens de escala de cinza
- SIFT é um algoritmo patenteado, o que significa que seu uso é restrito em alguns contextos
  - Em contraste, o SURF não é patenteado e pode ser usado livremente



Gonzalez, R. C.; Woods R. E.  
Processamento de imagens digitais.  
Editora Blucher, 2000.



Piemontez R. A.  
Detecção de pontos faciais (Facemark) com OpenCV.  
Disponível em: <https://visaocomputacional.com.br/deteccao-de-pontos-faciais-facemark-com-opencv/>,  
202024.



Prateek, J., Millan, E. D., e Vinivius, G.  
OpenCV by Example.  
Packt Publishing, 2016.



Villán, A. F.  
Mastering OpenCV 4 with Python.  
Packt Publishing, 2019.



Wiggers, K. L.

Notas de aula – Processamento de Imagens: segmentação de imagens.

UTFPR. Pato Branco, PR, 2024.